



# SVD Review

Mingdong Wu

Intro

SVD & PCA? Singular vec?

降维? 图像压缩? Gx讲过SVD?

主成分是啥?

So on...

## GX' s SVD

设  $A$  是  $m \times n$  实矩阵. 由于  $AA^T$  实对称,  
存在正交矩阵  $P$ , 使得

$A$  列向量的主方向, 主...

$$AA^T = \underbrace{[\beta_1 \beta_2 \cdots \beta_m]}_P \begin{bmatrix} \lambda_1 & & & \\ & \ddots & & \\ & & \lambda_r & \\ & & & 0 \end{bmatrix} P^T$$

且  $AA^T$  的特征值非负:

$$\lambda_1 \geq \dots \geq \lambda_r > \lambda_{r+1} = \dots = 0$$

## GX' s SVD

由

$$(\mathbf{A}^T \mathbf{P})^T \mathbf{A}^T \mathbf{P} = \mathbf{P}^T \mathbf{A} \mathbf{A}^T \mathbf{P} = \begin{bmatrix} \lambda_1 & & & \\ & \ddots & & \\ & & \lambda_r & \\ & & & \mathbf{0} \end{bmatrix}$$

知  $\mathbf{A}^T \mathbf{P}$  的  $m$  个列向量  $\mathbf{A}^T \beta_1, \dots, \mathbf{A}^T \beta_m$

两两正交且长度分别为

$$\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_r}, 0, \dots, 0$$

## GX' s SVD

令  $\gamma_i = \frac{1}{\sqrt{\lambda_i}} A^T \beta_i$ ,  $i = 1, \dots, r$ ;

则  $\gamma_1, \dots, \gamma_r$  可扩充成  $\mathbf{R}^n$  的标准正交基

$$\gamma_1, \dots, \gamma_r, \dots, \gamma_n$$

记正交矩阵  $Q = [\gamma_1 \dots \gamma_n]$ , 则有

$$A^T P = A^T [\beta_1 \dots \beta_m] = Q \begin{bmatrix} \sqrt{\lambda_1} & & & \\ & \ddots & & \\ & & \sqrt{\lambda_r} & \\ & & & 0 \end{bmatrix}_{n \times m}$$

即  $A = P S Q^T$

GX' s SVD

# Singular Value Decomposition

每个实矩阵  $A$  都能写成  $A = P S Q^T$

$$= [\beta_1 \ \beta_2 \ \cdots \ \beta_m] \begin{bmatrix} \sqrt{\lambda_1} & & & \\ & \ddots & & \\ & & \sqrt{\lambda_r} & \\ & & & \mathbf{0} \end{bmatrix}_{m \times n} \begin{bmatrix} \gamma_1^T \\ \gamma_2^T \\ \vdots \\ \gamma_n^T \end{bmatrix}$$

$$= \sqrt{\lambda_1} \beta_1 \gamma_1^T + \sqrt{\lambda_2} \beta_2 \gamma_2^T + \cdots + \sqrt{\lambda_r} \beta_r \gamma_r^T$$

## Two Perspective

- 下面我们从两种不同的视角分析SVD
- 一种是John的，将矩阵 $A$ 视为向量簇
- 另一种是将矩阵 $A$ 看成一个线性映射
- 咱先从John的开始

## Task Definition

- 给定n个d维向量，求最优 $k(\leq r)$ 维子空间？
  - Linear
- 什么是“最优k维子空间”？
  - n个向量在该子空间上“成分”最大
- 什么是“成分”？
  - 投影的Frobenius norm
- Frobenius norm?

$$\|A\|_F = \sqrt{\sum_{j,k} a_{jk}^2}.$$



## Task Definition

- 给定一个k-subspace, 设它的一组标准正交基为 $\{w_1, w_2 \dots w_k\}$
- 对向量簇 $\{\alpha_1, \alpha_2 \dots \alpha_n\}$ , 令 $A = [\alpha_1^T, \alpha_2^T \dots \alpha_n^T]^T$
- 则 $\{\alpha_1, \alpha_2 \dots \alpha_n\}$ 到 $\{w_1, w_2 \dots w_k\}$ 投影的Frobenius norm:

$$|Aw_1|^2 + |Aw_2|^2 + \dots + |Aw_{k-1}|^2 + |Aw_k|^2$$

- 问题就转化为, 给定A, 找一组标准正交基 $\{w_1, w_2 \dots w_k\}$ , 使上面的式子最大

## Greedy Approach

- 如何找最优的 $\{w_1, w_2 \dots w_k\}$ 呢？先考虑一个朴素的想法：
- Step 1. 先找一个 $v_1$  ( $|v_1|=1$ )使 $\{\alpha_1, \alpha_2 \dots \alpha_n\}$ 到 $v_1$ 的“成分”最大
  - John定义的“成分”(Component)? 就是“投影的” **Frobenius norm**

$$v_1 = \arg \max_{|v|=1} |Av|. \quad \sigma_1(A) = |Av_1|$$

- 而找到的 $v_1$ 就叫“(right)singular vector”，刻画的是“主方向”
- $\sigma_1^2(A)$ 就叫“singular value”，刻画的是向量簇在 $v_1$ 上的“主成分”

## Greedy Approach

- Step 2. 再找  $v_2$ , 使  $v_2$  和  $v_1$  正交的同时,  $\{\alpha_1, \alpha_2 \dots \alpha_n\}$  到  $v_1$  的“成分”最大
- ...
- Step  $m$ . 找  $v_m$ , 使  $v_m$  与  $\{v_1, v_2 \dots v_{m-1}\}$  正交同时,  $\{\alpha_1, \alpha_2 \dots \alpha_n\}$  到  $v_m$  的“成分”最大
- 当算法执行  $m > r$  步之后, 会发现:
- 算法自然停止

$$\max_{\substack{\mathbf{v} \perp \mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r \\ |\mathbf{v}|=1}} |A\mathbf{v}| = 0.$$

## Greedy Approach Works

- 贪心找出来的k个奇异向量 $\{v_1, v_2 \dots v_k\}$ 为何恰好就是最优k-subspace?
- 归纳法证明:
  - K=1显然
  - K=k-1 时, 假设命题成立, 考虑K=k的情形
  - 如果 $\{w_1, w_2 \dots w_k\}$ 是最优的k-subspace的标准正交基
  - $\{v_1, v_2 \dots v_{k-1}\}$ 是最优的(k-1)-subspace
  - 总能调整 $w_k$ , 使其与空间 $\{v_1, v_2 \dots v_{k-1}\}$ 正交

$$|Aw_k|^2 \leq |Av_k|^2.$$

$$|Aw_1|^2 + |Aw_2|^2 + \dots + |Aw_{k-1}|^2 \leq |Av_1|^2 + |Av_2|^2 + \dots + |Av_{k-1}|^2$$

## Singular Vectors and Values

- 回过头研究下我们找到的 $\{v_1, v_2 \dots v_r\}$ 和 $\{\sigma_1, \sigma_2 \dots \sigma_r\}$ 的性质
- 性质1.  $\{\alpha_1, \alpha_2 \dots \alpha_n\}$ 可以被 $\{v_1, v_2 \dots v_r\}$ 线性表出
- $\alpha_i = \sum_j (\alpha_i, v_j) v_j$
- 性质2. “A的成分” 也应等于 “A被分解后的成分”

$$\sum_{j=1}^n |\mathbf{a}_j|^2 = \sum_{j=1}^n \sum_{i=1}^r (\mathbf{a}_j \cdot \mathbf{v}_i)^2 = \sum_{i=1}^r \sum_{j=1}^n (\mathbf{a}_j \cdot \mathbf{v}_i)^2 = \sum_{i=1}^r |A\mathbf{v}_i|^2 = \sum_{i=1}^r \sigma_i^2(A).$$

- 定义left singular vec:  $\mathbf{u}_i = \frac{1}{\sigma_i(A)} A\mathbf{v}_i.$

## Singular Value Decomposition

- 给定矩阵A的right singular vec  $\{v_1, v_2 \dots v_r\}$ 和left singular vec  $\{u_1, u_2 \dots u_r\}$ 以及singular value  $\{\sigma_1, \sigma_2 \dots \sigma_r\}$

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

## Singular Value Decomposition

• 证明John版的SVD  $A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$

• Lemma: 如果对任意 $\mathbf{v}$ ,  $A\mathbf{v} \stackrel{i=1}{=} B\mathbf{v}$ , 那么  $A = B$

• 对任意的 $\mathbf{v}$ , 如果它在 $\{\mathbf{v}_1, \mathbf{v}_2 \dots \mathbf{v}_r\}$ 张成的空间里:

$$\sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T \mathbf{v}_j = \sigma_j \mathbf{u}_j = A\mathbf{v}_j \qquad A\mathbf{v} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T \mathbf{v}$$

• 如果它和 $\{\mathbf{v}_1, \mathbf{v}_2 \dots \mathbf{v}_r\}$ 正交, 那么  两端都为0(左右依旧相等)

• 利用lemma SVD得证

• 想想这和GX给出SVD的方式有什么不同?

## Singular Value Decomposition

- 我知道怎么用John的算法求SVD，但有没有看起来更方便的算法？
- 我们构造个矩阵B

$$\begin{aligned} B &= A^T A = \left( \sum_i \sigma_i \mathbf{v}_i \mathbf{u}_i^T \right) \left( \sum_j \sigma_j \mathbf{u}_j \mathbf{v}_j^T \right) \\ &= \sum_{i,j} \sigma_i \sigma_j \mathbf{v}_i (\mathbf{u}_i^T \cdot \mathbf{u}_j) \mathbf{v}_j^T = \sum_i \sigma_i^2 \mathbf{v}_i \mathbf{v}_i^T. \end{aligned}$$

- 可以发现B的特征值和特征向量恰好就是(right)singular vec 和 singular value:

$$B \mathbf{v}_j = \left( \sum_i \sigma_i^2 \mathbf{v}_i \mathbf{v}_i^T \right) \mathbf{v}_j = \sigma_j^2 \mathbf{v}_j,$$



## Truncation

- 有了SVD之后，我们能很自然地开始考虑k-部分和

$$A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T \longrightarrow A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

- 性质1:  $A_k$ 的行向量，正是A的行向量投影到 $\{\mathbf{v}_1, \mathbf{v}_2 \dots \mathbf{v}_k\}$ 的结果

$$\mathbf{a} \longrightarrow \sum_{i=1}^k (\mathbf{a} \cdot \mathbf{v}_i) \mathbf{v}_i^T$$

$$A \mathbf{v}_i = \sigma_i \mathbf{u}_i \text{ and } A^T \mathbf{u}_i = \sigma_i \mathbf{v}_i.$$

## Truncation

- 性质2: 对于rank不超过k的任意矩阵B:

$$\|A - A_k\|_F \leq \|A - B\|_F \quad A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

- Idea: 首先A-B的“成分”大小就是A-B每一行行向量“成分”大小之和。考虑每一对对应的A B行向量 $\alpha, \beta$ ，固定B行向量 $\beta$ 方向后， $\beta$ 模长只有取 $\alpha$ 在 $\beta$ 方向上投影大小时， $|\alpha - \beta|$ 才最小。

## Truncation

- 性质2: 对于rank不超过k的任意矩阵B:

$$\|A - A_k\|_F \leq \|A - B\|_F$$

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

- 这个性质带来了两个SVD的应用: 图片压缩、数据(比如高维向量)降维(即PCA)

## Image Compression


- 将上面的性质2，应用到图片压缩
- 如果存一张图 复杂度 $O(mn)$
- 但如果能限制这张图到k-rank 而 $k \ll \min\{n,m\}$
- 存储的空间复杂度可以降到 $O(k * \max(n,m))$
- (由性质2)而所有(不超过)k-rank矩阵中，SVD的k-部分和是最好的估计

$$\|A - A_k\|_F \leq \|A - B\|_F$$

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

## PCA

给你一堆高维空间中的点，如何给它们找一组“好”的正交基？



We find better axes!

## PCA

首先坐标系的中心应该是点云的重心  
那我们先将所有 $\mathbf{x}_i$ 中心化变成 $\mathbf{y}_i$ :

$$\mathbf{y}_i = \mathbf{x}_i - \mathbf{m}$$



然后构造以下矩阵:

$$S = YY^T, \quad Y = \begin{bmatrix} | & | & \cdots & | \\ \mathbf{y}_1 & \mathbf{y}_2 & \cdots & \mathbf{y}_n \\ | & | & \cdots & | \end{bmatrix}$$

## PCA

考虑一个从原点出发的单位向量 $v$ ，那么向量簇 $\{y_1, y_2 \dots y_n\}$ 在 $v$ 方向上的“成分”，刻画了向量簇 $v$ 在方向的方差：

$$\text{var}(L) = \frac{1}{n} \sum_{i=1}^n \| \mathbf{x}'_i - \mathbf{m} \|^2$$



## PCA

把该式进一步展开

$$\text{var}(L) = \frac{1}{n} \sum_{i=1}^n \| \mathbf{x}'_i - \mathbf{m} \|^2$$

$$\text{var}(\ell) = \frac{1}{n} \sum_{i=1}^n \| \mathbf{x}'_i - \mathbf{m} \|^2 = \frac{1}{n} \sum_{i=1}^n (\mathbf{v}^\top \mathbf{y}_i)^2 = \frac{1}{n} \| \mathbf{v}^\top Y \|^2$$

$$= \frac{1}{n} (\mathbf{v}^\top Y)(\mathbf{v}^\top Y)^\top = \frac{1}{n} \mathbf{v}^\top Y Y^\top \mathbf{v} = \frac{1}{n} \langle S \mathbf{v}, \mathbf{v} \rangle .$$

矩阵 $Y Y^\top$ 究竟在刻画什么？



## Evaluation Matrix

这是个度量阵，刻画的是对单位向量 $\mathbf{v}$ ，向量簇 $\{\mathbf{y}_1, \mathbf{y}_2 \dots \mathbf{y}_n\}$ 在 $\mathbf{v}$ 上成分的大小！


$$\begin{aligned}\text{var}(\ell) &= \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}'_i - \mathbf{m}\|^2 = \frac{1}{n} \sum_{i=1}^n (\mathbf{v}^\top \mathbf{y}_i)^2 = \frac{1}{n} \|\mathbf{v}^\top \mathbf{Y}\|^2 \\ &= \frac{1}{n} (\mathbf{v}^\top \mathbf{Y})(\mathbf{v}^\top \mathbf{Y})^\top = \frac{1}{n} \mathbf{v}^\top \mathbf{Y} \mathbf{Y}^\top \mathbf{v} = \frac{1}{n} \langle S \mathbf{v}, \mathbf{v} \rangle.\end{aligned}$$

## Two Perspective


- 我们从两种不同的视角分析SVD
- 一种是John的，将矩阵 $A$ 视为向量簇
- 另一种是将矩阵 $A$ 看成一个线性映射
- 咱继续从线性映射的角度观察

## Linear Mapping

- 所有的线性映射 基本都长这样：



先“转”下坐标轴，  
再改变模长？



## Linear Mapping

- 如果映射**A**是可对角化的，那就存在一组基使得**A**在这组基下的矩阵是对角
- 但对general case，如果**A**是不可对角化的方阵？甚至是 $m * n$ ？
- (加条件)一组基不够，再来一组：

$$\mathbf{A} : \mathbf{U} \rightarrow \mathbf{V}$$

$$\mathbf{A} \quad (\alpha_1, \dots, \alpha_n) \quad (\beta_1, \dots, \beta_m)$$

$$\mathbf{A} (\alpha_1, \dots, \alpha_n) = (\beta_1, \dots, \beta_m) \mathbf{A}$$

## Linear Mapping

- 当基  $U$   $V$  变化时，映射  $A$  对应的矩阵也随之改变，什么时候最简单？能否化成对角型？

设  $(\alpha_1', \dots, \alpha_n') = (\alpha_1, \dots, \alpha_n) Q,$

$$(\beta_1', \dots, \beta_m') = (\beta_1, \dots, \beta_m) P,$$


$P, Q$  是正交矩阵，则

$$\begin{aligned} A(\alpha_1', \dots, \alpha_n') &= [A(\alpha_1, \dots, \alpha_n)] Q \\ &= (\beta_1, \dots, \beta_m) [A \quad Q] \\ &= (\beta_1', \dots, \beta_m') [P^T A \quad Q] \end{aligned}$$


## Linear Mapping

- 有了SVD 一目了然

$$A[\gamma_1 \ \gamma_2] = [\beta_1 \ \beta_2] \begin{bmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \end{bmatrix}$$



$A^T A$  特征向量




$AA^T$  特征向量

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i \text{ and } A^T \mathbf{u}_i = \sigma_i \mathbf{v}_i.$$

## Linear Mapping


- 回过头来再看最开始提到的linear mapping性质：



定理：

$$A = P S Q^T = (P Q^T) Q S Q^T$$

欧氏空间上的线性变换都可唯一地写成  
一个正交变换与一个对称变换的乘积。



## Understanding Principal Component

- SVD也叫主成分分解，式子中的 $\mathbf{u}_i \mathbf{v}_i^T$ 正是不同的“主成分”
- 怎么(不严格地)理解主成分呢？
- 还是两种角度 把 $\mathbf{A}$ 看成行向量组合、或看成一个线性映射？

$$\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T.$$

- 仅Make sense一下，就不写slides上了



## Other Matrix Decomposition

- SVD的分解是和矩阵自身相关的
- 能不能直接找一组基, independent from matrix 同时又有很强的解释性和应用呢?
- Spectral Decomposition

## Other Matrix Decomposition

- Spectral Decomposition
- (就是离散傅里叶)

$$\begin{bmatrix} \frac{1}{\sqrt{2}} & \cos \frac{\pi}{16} & \cos \frac{2\pi}{16} & \dots & \cos \frac{7\pi}{16} \\ \frac{1}{\sqrt{2}} & \cos \frac{3\pi}{16} & \cos \frac{6\pi}{16} & \dots & \cos \frac{3 \times 7\pi}{16} \\ & & & \dots & \\ \frac{1}{\sqrt{2}} & \cos \frac{15\pi}{16} & \cos \frac{2 \times 15\pi}{16} & \dots & \cos \frac{7 \times 15\pi}{16} \end{bmatrix}_{8 \times 8}$$

列向量由低频到高频排列

$\{\alpha_i \alpha_j^T\}$  构成

线性空间

$M_{8,8}(\mathbb{R})$  的基底

$$X = \text{[Image]} \leftarrow$$

线性表出的系数  
如何计算?

$\alpha_i \alpha_j^T$  ( $0 \leq i, j \leq 7$ ) 的图像

